Farrel Putra Imanuel The - 2802391883

Bagian C: Laporan dan Analisis (Bobot: 35%)

Ringkasan Eksperimen

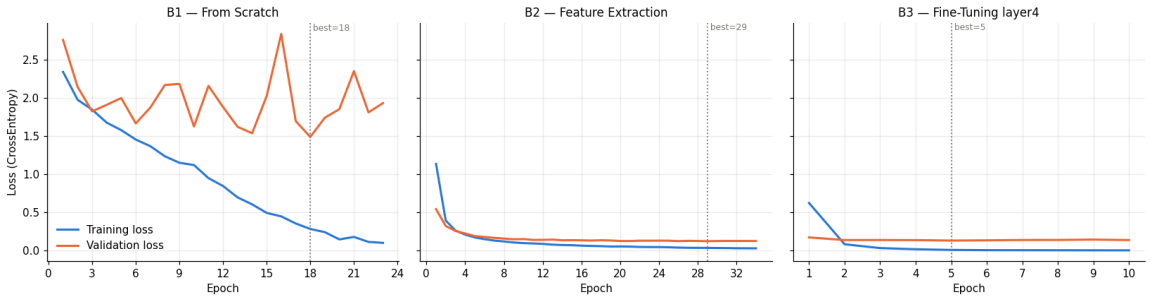
Transfer learning menaikkan Macro F1 test dari 0,584 (from scratch, B1) menjadi 0,946–0,970 (B2–B5), sedangkan fine-tuning `layer4` dan augmentasi tidak memberi peningkatan berarti dibanding feature extraction. Dataset: subset 10 kelas Oxford-IIIT Pet (kucing: Abyssinian, Bengal, Egyptian Mau, Maine Coon, Siamese; anjing: Beagle, Boxer, Pug, Samoyed, Shiba Inu) sebanyak 1.986 citra, dibagi stratified menjadi 1.390 train, 298 validation, dan 298 test. Protokol seragam: ResNet-18, input 224 × 224 dengan normalisasi ImageNet, batch size 32, AdamW (weight decay 10^{-2}), CrossEntropyLoss, early stopping pada validation loss (patience 5), seed 42, GPU Tesla T4. B1–B3 tanpa augmentasi; B4 adalah B3 dengan augmentasi; B5 menjalankan konfigurasi B2 (terbaik di antara B2–B4 menurut Macro F1 validasi) pada EfficientNet-B0. Lapisan yang dibekukan dijaga dalam mode `eval()` agar BatchNorm tidak berubah.

C1. Tabel Konsolidasi dan Visualisasi Pembelajaran

Tabel 1. Konsolidasi hasil B1–B5. Epoch konvergen = epoch dengan validation loss terendah / total epoch; gap = akurasi latih (tanpa augmentasi) dikurangi akurasi validasi.

Kode	Strategi	Trainable params	Learning rate	Epoch konvergen	Waktu (detik)	Akurasi val	Macro F1 test	Gap
B1	From scratch	11.181.642	1e-3	18 / 23	135,7	0,5738	0,5839	0,3816
B2	Feature extraction (`fc`)	5.130	1e-3	29 / 34	105,4	0,9732	0,9457	0,0254
B3	Fine-tuning `layer4` + `fc`	8.398.858	1e-4 / 1e-3	5 / 10	33,5	0,9597	0,9527	0,0403
B4	B3 + augmentasi	8.398.858	1e-4 / 1e-3	5 / 10	75,8	0,9564	0,9493	0,0336
B5	EfficientNet-B0, feature extraction	12.810	1e-3	20 / 25	85,3	0,9698	0,9693	0,0288

Hanya B1 yang berbeda jelas dari kondisi lain. Selisih B2, B3, dan B4 hanya satu sampai dua citra pada test set 298 citra (1 citra = 0,34 poin persentase) sehingga tidak bermakna. Pada Gambar 1, validation loss B1 berosilasi (1,49–2,83) sementara training loss turun ke 0,10; B2 konvergen stabil (training 0,029, validation 0,124); B3 mencapai validation loss minimum pada epoch 5 (0,1305) sementara training loss terus turun ke 0,0022.



Gambar 1. Training loss (biru) dan validation loss (oranye) pada B1, B2, B3; garis putus-putus = epoch terbaik.

C2. Pembahasan Analisis Komparatif

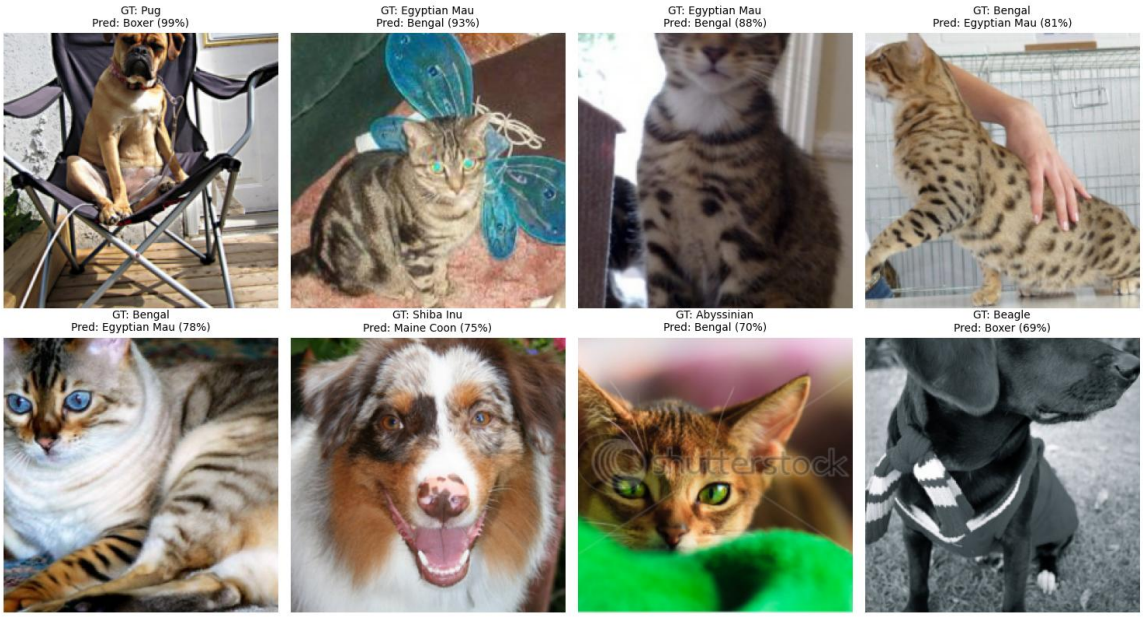
1. B1 vs. B2 dan B3. B1 mencapai akurasi validasi 0,5738, jauh di bawah B2 (0,9732) dan B3 (0,9597). B1 melatih 11,18 juta parameter dari inisialisasi acak dengan hanya 1.390 citra (sekitar 8.000 parameter per citra), sehingga model menghafal data latih (akurasi 0,9554, gap 0,3816) tanpa fitur yang general. B2 dan B3 memakai hierarki fitur ImageNet yang dapat digunakan ulang (Slide 10–12) pada domain yang dekat, dan input 224 × 224 sesuai resolusi pelatihan asli sehingga tidak ada ketidaksesuaian resolusi (Slide 28). Akurasi validasi pada epoch pertama sudah 0,883 (B2) dan 0,943 (B3), dibanding 0,188 (B1).

2. Feature extraction vs. fine-tuning bertahap. B2 lebih stabil, B3 lebih cepat konvergen, dan keduanya setara dalam akurasi. B2 hanya melatih 5.130 parameter dengan validation loss terendah 0,1217 (B3: 0,1305) dan gap 0,0254 (B3: 0,0403). B3 melatih 8,4 juta parameter dan mencapai akurasi latih 100% sejak epoch 6, sehingga kapasitas tambahan `layer4` tidak termanfaatkan pada 1.390 citra. B3 konvergen pada epoch 5 (33,5 detik) dibanding epoch 29 pada B2 (105,4 detik); waktu per epoch keduanya serupa (3,35 vs. 3,10 detik), tetapi linear head B2 memerlukan banyak epoch. Differential learning rate (10^{-4} untuk `layer4`, 10^{-3} untuk `fc`) melindungi bobot pretrained (Slide 16), namun selisih Macro F1 test B3–B2 hanya 0,007 (dua citra). Pada volume data ini, fine-tuning membeli kecepatan konvergensi, bukan akurasi.

3. Peran augmentasi (B4). Augmentasi mengecilkan gap dari 0,0403 (B3) menjadi 0,0336 (B4), tetapi tidak meningkatkan generalisasi: penurunan gap berasal dari turunnya akurasi latih (1,0000 menjadi 0,9899), bukan naiknya akurasi validasi (0,9597 menjadi 0,9564, selisih satu citra). Validation loss terbaik sedikit lebih tinggi (0,1349 vs. 0,1305), akurasi validasi lebih berfluktuasi (0,930–0,960 vs. 0,943–0,963), dan waktu per epoch dua kali lipat (7,58 vs. 3,35 detik) karena augmentasi berjalan di CPU (Slide 20). Dua penjelasan yang belum diuji: early stopping (patience 5) menghentikan B4 pada epoch 10, mungkin sebelum efek regularisasi muncul, dan rotasi serta color jitter dapat mengubah isyarat warna dan pola bulu yang membedakan ras. Dengan demikian, augmentasi hanya meredam overfitting secara marginal.

C3. Failure Analysis

Model B2 salah pada 16 dari 298 citra uji (5,4%); 12 di antaranya berasal dari Bengal (5), Egyptian Mau (4), dan Abyssinian (3), yaitu tiga ras kucing berbulu pendek berpola. Gambar 2 menampilkan 8 kesalahan dengan confidence tertinggi (69%–99%), berurutan sesuai nomor pada Tabel 2.



Gambar 2. Delapan kesalahan dengan confidence tertinggi pada model B2 (GT = label aktual, Pred = prediksi dan confidence).

Tabel 2. Sampel misklasifikasi dan hipotesis penyebab

No	Aktual → Prediksi (confidence)	Hipotesis penyebab
1	Pug → Boxer (0,994)	Individu atipikal (warna fawn, moncong lebih panjang) mirip Boxer; latar kursi dan pintu mengganggu; kemungkinan label noise.
2	Egyptian Mau → Bengal (0,933)	Oklusi kostum sayap biru yang mencolok; pola tabby berbintik menyerupai Bengal.
3	Egyptian Mau → Bengal (0,883)	Pemotongan: wajah terpotong di tepi atas; bercak gelap besar menyerupai Bengal.
4	Bengal → Egyptian Mau (0,811)	Pose samping ekstrem, sebagian tertutup tangan, latar

No	Aktual → Prediksi (confidence)	Hipotesis penyebab
		kandang; kedua ras sama-sama berbintik.
5	Bengal → Egyptian Mau (0,783)	Varian warna atipikal (putih-krem, mata biru); close-up memotong sebagian tubuh.
6	Shiba Inu → Maine Coon (0,748)	Dugaan label noise: anjing bermantel panjang merle tidak menyerupai Shiba Inu; bulu tebal memicu prediksi kucing berbulu panjang (bias tekstur).
7	Abyssinian → Bengal (0,703)	Wajah tertutup objek hijau tidak fokus dan ada watermark (bias latar).
8	Beagle → Boxer (0,689)	Isyarat warna hilang: mantel gelap tanpa pola tricolor, citra hampir grayscale, memakai syal, pose samping.

Hipotesis ini berdasarkan pemeriksaan visual dan belum diuji. Tiga pola muncul: (i) ambiguitas antar-ras kucing berpola (sampel 2–5 dan 7); (ii) kondisi citra sulit, yaitu oklusi, pemotongan, pose ekstrem, dan blur (sampel 2, 3, 4, 7, 8); (iii) kemungkinan label noise atau individu atipikal (sampel 1 dan 6). Kesalahan dengan confidence di atas 90% (sampel 1 dan 2) menunjukkan bahwa confidence softmax tidak terkalibrasi.

C4. Rekomendasi Rekayasa dan Batasan Eksperimen

Untuk data terbatas (sekitar 140 citra latih per kelas) dengan domain dekat ImageNet, strategi paling optimal adalah feature extraction pada backbone pretrained (B2), atau EfficientNet-B0 (B5) bila ukuran model dibatasi: akurasinya setara fine-tuning, dengan parameter terlatih paling sedikit, kurva paling stabil, dan gap terendah. Kondisi berlakunya:

- **Feature extraction (B2)** sebagai default, bila domain mirip citra alami ImageNet, input mendekati 224 × 224, dan komputasi terbatas.
- **Fine-tuning `layer4` (B3)** bila perlu iterasi cepat (konvergen epoch 5 vs. 29) atau pergeseran domain lebih besar; wajib early stopping, checkpoint terbaik, dan BatchNorm frozen. Keuntungannya pada domain jauh tidak diuji di sini.
- **EfficientNet-B0 (B5)** bila ukuran atau latensi dibatasi: Macro F1 test 0,9693 dengan 4,02 juta parameter (ResNet-18: 11,18 juta); bersifat indikatif karena single seed.
- **Hindari from scratch (B1)** pada data sangat sedikit, dan gunakan **augmentasi** hanya bila gap melebar, dengan patience lebih panjang.

Secara operasional, audit label dan penambahan data untuk pasangan Bengal–Egyptian Mau lebih bermanfaat daripada mengganti arsitektur, dan prediksi berkeyakinan rendah sebaiknya ditinjau manusia atau dikalibrasi (misalnya temperature scaling).

Batasan studi:

- **Single seed (42):** selisih B2–B4 (satu sampai dua citra) tidak dapat dibedakan dari variasi acak; diperlukan beberapa seed atau cross-validation.
- **Test set kecil:** 298 citra (28–30 per kelas), sehingga satu citra mengubah akurasi 0,34 poin persentase.
- **Cakupan terbatas:** 10 kelas dari satu dataset dengan domain dekat ImageNet; temuan tentang fine-tuning belum tentu berlaku pada domain jauh (misalnya medis atau industri).
- **Hyperparameter tidak dituning:** learning rate, weight decay, dan patience seragam; B1 tanpa scheduler sehingga selisih B1 kemungkinan terlalu besar; augmentasi hanya satu konfigurasi; B5 memakai learning rate B2.
- **Komputasi dan analisis:** satu GPU T4 dengan dua worker CPU (durasi B4 dipengaruhi bottleneck CPU); analisis C3 dan C5 bersifat kualitatif dan belum diuji dengan ablation.

C5. Eksplorasi Tambahan: Grad-CAM pada `layer4`

Grad-CAM dihitung pada keluaran `layer4` (peta 7 × 7, di-upsample ke 224 × 224) untuk B2 (`layer4` berbobot ImageNet) dan B3 (`layer4` di-fine-tune) pada empat citra uji yang sama (dipilih acak, seed 42); Gambar 3 menampilkan dua di antaranya.



Gambar 3. Grad-CAM `layer4`: citra asli, B2 (sebelum fine-tuning), dan B3 (sesudah fine-tuning).

Pada keempat sampel kedua model memprediksi dengan benar dan memusatkan aktivasi pada wajah, bukan latar belakang. Pada Beagle, aktivasi B3 tampak lebih terkonsentrasi di moncong dan pipi, sedangkan B2 lebih menyebar; pada dua citra Pug (tidak ditampilkan) peta hampir identik; pada Maine Coon kedua model turut menyorot tag kalung, kemungkinan isyarat spurious yang tidak hilang setelah fine-tuning. Pergeseran yang halus ini konsisten dengan C2: `layer4` hanya diperbarui dengan learning rate 10^{-4} dan fitur ImageNet-nya sudah relevan (Slide 29). Keterbatasannya, analisis ini kualitatif, hanya empat citra, dan peta 7 × 7 terlalu kasar untuk perubahan halus.